

СОДЕРЖАНИЕ

РЕФЕРАТ	3
ОСНОВНЫЕ ТЕРМИНЫ, ОПРЕДЕЛЕНИЯ И СОКРАЩЕНИЯ	4
1 ДИАГНОСТИКА ЗАБОЛЕВАНИЙ ВЕН И ГЛУБИННОЕ ОБУЧЕНИЕ	6
1.1 Цели и задачи исследования	6
1.2 Введение	6
1.3 Литературный обзор	7
2 АЛГОРИТМЫ И ДАННЫЕ	10
2.1 Граф кровеносной системы	10
2.2 Данные и аугментация	12
2.3 Нейронные сети, CNN и GAN	12
2.4 Парадигма PINN	13
3 ВЫЧИСЛИТЕЛЬНЫЕ ЭКСПЕРИМЕНТЫ И АНАЛИЗ РЕЗУЛЬТАТОВ	15
3.1 Полное описание кровеносной системы	15
3.2 Нейронная сеть	17
3.3 Результаты	19
3.4 Бифуркационный анализ	20
ЗАКЛЮЧЕНИЕ	21
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	22

РЕФЕРАТ

Исследование, представленное в курсовой работе, актуально в области медицины в контексте визуализации и диагностики. Использование сверточных нейронных сетей (CNN) для классификации медицинских изображений представляет собой растущую область интереса. Использование генеративно-сопоставительных сетей (GAN) для аугментации МРТ-сканирований решает проблему дисбаланса классов в исходных данных. Результаты экспериментов, проведенных в данном исследовании, демонстрируют относительную эффективность разработанной модели. Использование набора данных, дополненного различными соотношениями смешивания для исходного и сгенерированного наборов изображений МРТ, позволяет провести тщательную оценку предлагаемого подхода. Применяя представленные методы и проведя вычислительный эксперимент, получены следующие результаты. Применение парадигмы PINN позволило улучшить качество генерации МРТ-снимков по сравнению со стандартной моделью GAN. Наилучший результат был достигнут с использованием модели, в которую была интегрирована физическая информация о графе кровеносной системы. Предобученная модель продемонстрировала высокое качество работы как генератора, так и дискриминатора, что подтверждается стандартными метриками точности (Precision), показателем правильности классификации (Accuracy), полнотой (Recall) и комбинированной функцией потерь. Кроме того, генерируемые изображения получили более реалистичный вид, что говорит о значительном улучшении их правдоподобности по сравнению со стандартной моделью GAN.

ОСНОВНЫЕ ТЕРМИНЫ, ОПРЕДЕЛЕНИЯ И СОКРАЩЕНИЯ

Флебология — раздел медицины, изучающий строение, функции вен, а также разрабатывающий методы диагностики, лечения и профилактики заболеваний.

Гемодинамика — движение крови по сосудам, возникающее вследствие разности гидростатического давления в различных участках кровеносной системы.

Томография — метод, позволяющий получить поперечные срезы внутренних структур организма.

Магнитно-резонансная томография (МРТ) — метод диагностики, использующий магнитные поля и радиоволны для создания детальных изображений органов и тканей организма.

Теория бифуркаций динамических систем — область исследований, где изучается структура и свойства разделения фазового пространства в зависимости от изменений параметров (одного или нескольких) в системе.

Невязка — величина ошибки (расхождения) приближённого равенства.

Метод стрельбы (пристрелки) — численный метод, заключающийся в сведении краевой задачи к некоторой задаче Коши для той же системы дифференциальных уравнений. Суть: первое решение при последовательном изменении аргумента и повторении вычислений становится точнее.

Нейронная сеть — математическая модель, а также её программное или аппаратное воплощение, построенная по принципу организации и функционирования биологических нейронных сетей — сетей нервных клеток живого организма.

Свёрточная нейронная сеть (англ. convolutional neural network, CNN) — глубокая нейронная сеть, использующая сверточные слои, которые применяют определенное количество фильтров к входным данным для обнаружения и изучения локальных закономерностей, а также объединяющие слои для уменьшения размерности промежуточных представлений.

Генеративно-сопоставительная сеть (англ. Generative Adversarial Network, GAN) — глубокая нейронная сеть, состоящая из двух отдельных

моделей: сети генератора и сети дискриминатора. Сеть генератора создает синтетические данные, которые пытаются имитировать распределение реальных данных, в то время как сеть дискриминатора оценивает подлинность данных и предоставляет обратную связь генератору. Благодаря этому процессу генератор обучается производить все более и более убедительные синтетические данные, в то время как дискриминатор становится более эффективным оценщиком подлинности данных.

Физически информированная нейронная сеть (англ. *Physically Informed Neural Networks, PINN*) — нейронные сети, в структуру которых инкорпорированы знания о физических законах, которым подчиняются процессы, для которых используются данные модели. Диагностика заболеваний кровеносной системы — выявление патологических процессов в кровотоке человека.

1 ДИАГНОСТИКА ЗАБОЛЕВАНИЙ ВЕН И ГЛУБИННОЕ ОБУЧЕНИЕ

1.1 Цели и задачи исследования

Основная цель этого исследования — разработать точный и эффективный инструмент диагностики заболеваний системы кровообращения с использованием физически информированных нейронных сетей (PINN). Исследование направлено на интеграцию сверточных нейронных сетей (CNN) и генеративно-сопоставительных сетей (GAN) для решения проблемы дисбаланса классов в данных медицинских изображений и повышения точности диагнозов.

1.2 Введение

По данным многих мировых медицинских организаций [1; 2] число смертей от заболеваний сердечно-сосудистой системой превышает практически все остальные причины смертей, составляя треть от вообще всех смертей населения земли. Подобная статистика усугубляется еще и очень частыми и серьезными пандемиями, например COVID-19. Очень часто при различных инфекционных и других заболеваниях, осложнения в первую очередь сказываются на сердечно-сосудистой системе.

Для предотвращения необратимых последствий очень важна своевременная диагностика подобных заболеваний. Наиболее популярная и эффективные не-инвазивные методы диагностики это различные радиологические методы исследования, такие как МРТ (Магнитно-резонансная томография) и КТ (Компьютерная томография). С помощью данных методов врач-диагност получает послойные снимки различных внутренних органов с использованием ядерного магнитного резонанса.

Основная проблема с томографией заключается в том, что на обработку набора снимков врач затрачивает в среднем не менее 2-3 часов. В контексте медицины лишнее время может быть критично для жизни и здоровья пациента, в связи с чем было предложено использование нейронных сетей для обработки снимков и помощи с диагностикой пациента.




Рисунок 1 — Пример МРТ-снимков нижней части тела человека

1.3 Литературный обзор

Использование методов глубокого обучения в медицинской диагностике в последние годы показало многообещающие результаты в виде повышения точности прогноза различных заболеваний.

В одном из соответствующих исследований [3], представлен новый метод классификации изображений сетчатки по артериям и венам, который имеет решающее значение для автоматического измерения отношения диаметра артерии к диаметру вены (AVR). Предлагаемый метод на основе локального двоичного шаблона (LBP) устойчив к изображениям с низкой контрастностью и низким качеством и включает дополнительную информацию о текстуре и форме AV.

Другое исследование [4] фокусируется на выявлении признаков диабетической ретинопатии (DR), включая кровеносные сосуды и экссудаты. Кровеносные сосуды сегментируются с использованием морфологических операций и пороговых значений, в то время как экссудаты сегментируются с использованием кластеризации k-средних и определения контуров. Также представлена модель глубокой сверточной нейронной сети (DCNN) для автоматической диагностики DR с точностью 75,73%.

Исследование Mohamed Abdou и др., содержит обзор более 50 исследовательских работ [5–7] по алгоритмам компьютерного зрения для анализа изображений микроциркуляции. Авторы представляют руководство по мето-

дам, позволяющим исследователям разрабатывать свои собственные системы и алгоритмы анализа микроциркуляции.

В работе [8] предложена сеть фильтрации, ориентированная на сосуды (VOF-Net), для сегментации сети сосудов головного мозга по данным магнитно-резонансной ангиографии (MRA) и компьютерной томографической ангиографии (СТА). VOF-Net встраивает знания предметной области в сверточную нейронную сеть и использует ориентированные фильтры для кровеносных сосудов для улучшения производительности сегментации.

Также, исследование [9] и др. подчеркивает важность методов на основе искусственного интеллекта в медицинской визуализации для обнаружения, классификации, прогнозирования и прогноза. Авторы подчеркивают необходимость интеграции множества источников информации, включая визуализацию, клинические и биологические данные, для улучшения диагностики и прогноза.

В работе [10] представлена модификация повсеместно используемой архитектуры U-Net для сегментации и последующей классификации томографических снимков. Данная модель изначально была придумана для работы с медицинскими изображениями, но в дальнейшем получила повсеместное использование.

Также есть альтернативное использование сверточных нейросетей как в работе [11] для геометрических нейронных сетей для построения модели предсердий по различным радиологическим снимкам. Для экспериментов по снимкам реконструируется само предсердие и затем по нему строится геометрическая модель и исследуется его работа.

В данных [12; 13] работах рассматриваются различные перспективы приложения нейронных сетей к диагностике сердечно-сосудистых заболеваний. Нейронные сети по-тихоньку проникают во все сферы нашей жизни, поэтому неудивительно активное приложение глубинного обучения в медицине. В последние годы наблюдается постоянное появление новых передовых моделей, которые становятся лидерами в своей области, и это происходит практически каждый месяц. Этот активный прогресс делает возможным предположить, что в ближайшем будущем нейронные сети смогут стать неотъемлемыми помощниками для медицинского персонала, особенно для врачей.

В целом, эти исследования дают всесторонний обзор современного состояния в применении методов глубокого обучения для анализа медицинской визуализации и диагностики, подчеркивая потенциал повышения точности и эффективности диагностики заболеваний.

2 АЛГОРИТМЫ И ДАННЫЕ

2.1 Граф кровеносной системы




Рисунок 2 — Полный граф кровеносной системы

Всю кровеносную систему человека при определенном приближении можно представить в виде графа. В графе вершинами будут являться точки соединения сосудов (также будем называть их точками бифуркации нашей кровеносной системы), а грани будут самими сосудами, как показано на рисунке выше.

Красные линии это артерии (в них кровь поступает от сердца), а синим обозначены вены (в них, наоборот, кровь течет в сторону сердца). Данный граф изображает кровеносную систему с очень большими допущениями, так

как все сосуды имеют различную пластичность, различные диаметры, скорость кровяного потока. Для более точного и более естественного понимания зависимостей работы сосудов будем подразумевать что мы работаем с обычными эластичными трубками с потоком жидкости по ним.

В современной гемодинамике самым важным для оценки работы сосуда является понимание особенностей кровотока в сосудах. Так как мы сделали допущение что сосуды это эластичные трубки с жидкостью, определим правила по которым эта жидкость движется.

Первым важным понятием является **закон сохранения масс**. Через точку бифуркации, даже если уменьшается диаметр сосуда, объем жидкости остается постоянным. Тогда в точке бифуркации данный закон будет выглядеть следующим образом:

$$S_1 v_1 = S_2 v_2 + S_3 v_3$$

где S_i - это площади сечения сосудов, а v_i - скорости кровотока по сосудам.

Чтобы описать движение жидкость по сосудам воспользуемся **уравнением Навье-Стокса** для несжимаемой жидкости:

$$\frac{\partial S}{\partial t} + \frac{\partial(Sv)}{\partial x} = const$$

$$\frac{\partial v}{\partial t} + \frac{\partial \left(\frac{v^2}{2} + \frac{p}{\rho} \right)}{\partial x} = const$$

где S – сечение сосуда, v – скорость крови, p – давление в сосуде, ρ – плотность крови. Первое описывает закон неразрывности, второе – закон сохранения импульса.

Для закона сохранения энергии будем использовать **уравнение Бернулли**:

$$\rho \frac{v^2}{2} + \rho \cdot g \cdot h + p = const$$

где ρ – плотность жидкости (крови), v – скорость потока, h – высота, p – давление, g – ускорение свободного падения.

2.2 Данные и аугментация

В медицине очень важное место занимает правовой аспект использования персональных данных пациентов. И как раз из-за многих ограничивающих законов (например GDPR), применение нейронных сетей в диагностике и вообще больницах мало распространено.

Для качественного обучения нейронных сетей для работы с изображениями ключевым фактором является достаточная обучающая выборка. В то же время при очень большом датасете, модели обученные на МРТ-снимках начинают быстро переобучаться, что логично, так как у новых пациентов может быть совершенно другое расположение сосудов и другие патологии.

Данные для данного исследования были предоставлены клиникой "Антирефлюкс". В итоговый обучающих датасет попали снимки 81 пациента, по 10 снимков на человека.

Задача аугментации медицинских изображений не так тривиальна как для обычных задач классификации изображений, так как МРТ-снимки должны изучаться при определенной ориентации, без помех и сжатий изображений, а так же без обрезания важной информации. Поэтому для аугментации было использовано только выравнивание изображений по осям, центрирование, нормализации контрастности и яркости.

2.3 Нейронные сети, CNN и GAN

Для классификации и распознавания медицинских изображений повсеместно используются различные модификации сверточных сетей. Сами по себе сверточные сети работают похожим образом, как человек сам воспринимает изображения. Исходное изображение разбивается на сегменты, затем в каждом сегменте распознаются определенные признаки, которые в итоге и влияют на финальную классификацию выхода сети.

Для выделения признаков используются различные ядра свертки, для уменьшения размерности матриц изображений - пулинг и в качестве функции активации используются сигмоиды и различные модификации ReLu.

В данной работе мы будем использовать генеративно-состязательные сети (GAN), которые будут генерировать новые изображения и затем выдавать вердикт. GAN состоит из генератора и дискриминатора. Генератор пы-




Рисунок 3 — Пример обработки МРТ снимка с использованием CNN

тается из шума создать изображение похожие на входные, в то время как дискриминатор оценивает "похожесть" сгенерированных и настоящих изображений. Использование GANa значительно повышает точность предсказаний.

2.4 Парадигма PINN

Для улучшение предсказаний модели можно использовать парадигму физического информирования нейронных сетей.

Для этого в архитектуру нейронной сети внедряются специальные слои, которые работают по некоторым записанным законам. В нашем слу-




Рисунок 4 — Интеграция парадигмы PINN в нейросеть

чае мы будем использовать для предсказаний различные правила такие как уравнение Навье-Стокса, уравнение Бернулли и закон сохранения масс.

3 ВЫЧИСЛИТЕЛЬНЫЕ ЭКСПЕРИМЕНТЫ И АНАЛИЗ РЕЗУЛЬТАТОВ

3.1 Полное описание кровеносной системы




Рисунок 5 — Малый граф системы кровообращения

Для внедрения в нейронную сеть информации о кровеносной системе, было решено использовать малый граф кровеносной системы. Малый граф состоит из 16 граней-сосудов и 12 точек бифуркаций. Поведение потока крови в этих точках бифуркаций будем описывать с помощью закона сохранения масс и уравнения Бернулли. Отдельный случай стоит рассмотреть для сердца. Сердце имеет две части предсердий, для каждого будем расписывать наши правил отдельно, также точки 5, 6 и 7 являются капиллярами и для них будем использовать схожие с предсердиями уравнения.

Каждая точка бифуркации имеет либо входящие два сосуда в один, либо наоборот два сосуда соединяются в один. Все уравнения будем расписывать используя индексы малого графа кровеносной системы. Тогда наш граф получит следующую систему уравнений:

Точка бифуркации	Невязки
$0 = 1 + 2$	$S_0v_0 - S_1v_1 - S_2v_2$ $p_0 + \frac{1}{2}\rho v_0^2 - p_1 - \frac{1}{2}\rho v_1^2$ $p_0 + \frac{1}{2}\rho v_0^2 - p_2 - \frac{1}{2}\rho v_2^2$
$1 = 3 + 4$	$S_1v_1 - S_3v_3 - S_4v_4$ $p_1 + \frac{1}{2}\rho v_1^2 - p_3 - \frac{1}{2}\rho v_3^2$ $p_1 + \frac{1}{2}\rho v_1^2 - p_4 - \frac{1}{2}\rho v_4^2$
$2 = 5 + 6$	$S_2v_2 - S_5v_5 - S_6v_6$ $p_2 + \frac{1}{2}\rho v_2^2 - p_5 - \frac{1}{2}\rho v_5^2$ $p_2 + \frac{1}{2}\rho v_2^2 - p_6 - \frac{1}{2}\rho v_6^2$
$7 = 4 + 6$	$S_7v_7 - S_4v_4 - S_6v_6$ $p_7 + \frac{1}{2}\rho v_7^2 - p_4 - \frac{1}{2}\rho v_4^2$ $p_7 + \frac{1}{2}\rho v_7^2 - p_6 - \frac{1}{2}\rho v_6^2$
$3 = 12$	$S_3v_3 - S_{12}v_{12}$ $p_{12} + \frac{1}{2}\rho v_{12}^2 - p_3 - \frac{1}{2}\rho v_3^2 - \Delta p_{\text{капилляры}}$
$5 = 11$	$S_5v_5 - S_{11}v_{11}$ $p_{11} + \frac{1}{2}\rho v_{11}^2 - p_5 - \frac{1}{2}\rho v_5^2 - \Delta p_{\text{капилляры}}$
$7 = 8$	$S_7v_7 - S_8v_8$ $p_8 + \frac{1}{2}\rho v_8^2 - p_7 - \frac{1}{2}\rho v_7^2 - \Delta p_{\text{капилляры}}$
$8 = 9 + 10$	$S_8v_8 - S_9v_9 - S_{10}v_{10}$ $p_8 + \frac{1}{2}\rho v_8^2 - p_9 - \frac{1}{2}\rho v_9^2$ $p_8 + \frac{1}{2}\rho v_8^2 - p_{10} - \frac{1}{2}\rho v_{10}^2$
$13 = 10 + 11$	$S_{13}v_{13} - S_{10}v_{10} - S_{11}v_{11}$ $p_{13} + \frac{1}{2}\rho v_{13}^2 - p_{10} - \frac{1}{2}\rho v_{10}^2$ $p_{13} + \frac{1}{2}\rho v_{13}^2 - p_{11} - \frac{1}{2}\rho v_{11}^2$
$14 = 12 + 9$	$S_{14}v_{14} - S_{12}v_{12} - S_9v_9$ $p_{14} + \frac{1}{2}\rho v_{14}^2 - p_{12} - \frac{1}{2}\rho v_{12}^2$ $p_{14} + \frac{1}{2}\rho v_{14}^2 - p_9 - \frac{1}{2}\rho v_9^2$
$15 = 13 + 14$	$S_{15}v_{15} - S_{13}v_{13} - S_{14}v_{14}$ $p_{15} + \frac{1}{2}\rho v_{15}^2 - p_{13} - \frac{1}{2}\rho v_{13}^2$ $p_{15} + \frac{1}{2}\rho v_{15}^2 - p_{14} - \frac{1}{2}\rho v_{14}^2$
$0 = 15$	$S_0v_0 - S_{15}v_{15}$ $p_0 + \frac{1}{2}\rho v_0^2 - p_{15} - \frac{1}{2}\rho v_{15}^2$

Для кровеносной системы мы будем использовать следующую таблицу с параметрами кровотока (данные предоставлены клиникой-коллаборатором):

№	Название сосудов	p, мм.рт	v, см/с	S, см ²
0	Segmentum aortae abdominalis	95.7	5.5	2.22
1	Arteria iliaca communis sinistra	95.7	4.7	1.3
2	Arteria iliaca communis dextra	95.7	4.7	1.3
3	Arteria femoralis sinistra	94.1–95.7	10.4	0.49
4	Arteria iliaca interna sinistra	94.4	14.75	0.07
5	Arteria femoralis dextra	94.1–95.7	10.4	0.49
6	Arteria iliaca interna dextra	94.4	14.75	0.07
7	Arteriae pelvis minoris	94.1–95.7	10.4	0.195
8	Venae pelvis minoris	5.9–7.0	8.2–9.1	0.235
9	Vena iliaca interna sinistra	5.5	7.35	0.135
10	Vena iliaca interna dextra	5.5	7.35	0.135
11	Vena femoralis dextra	5.1–6.5	8.8–10.4	0.49–0.58
12	Vena femoralis sinistra	5.1–6.5	8.8–10.4	0.49–0.58
13	Vena iliaca communis dextra	5.1	3.4	1.79
14	Vena iliaca communis sinistra	5.1	3.4	1.79
15	Segmentum renale venae cavae	5.1	3.8	3.16

3.2 Нейронная сеть

Реализации дискриминатора и генератора представлены ниже на картинках. На вход генератору подается вектор с шумом, затем из него генерируется картинка. Полученная картинка (на самом деле склейка из 10 снимков формата 300 на 300 пикселей) подается на вход дискриминатору.

В модификации вектор с шумом сначала преобразуется через блок в параметры кровеносной системы, затем уже полученные параметры преобразуются в изображения и отправляются к дискриминатору. Дискриминатор наоборот, преобразует изображения в систему параметров и по этим параметрам через линейные слои делается вердикт. Каждая из модифицированных моделей обладает двумя выходами сети: у генератора - параметры кровеносной системы и изображение, а у дискриминатора - параметры кровеносной

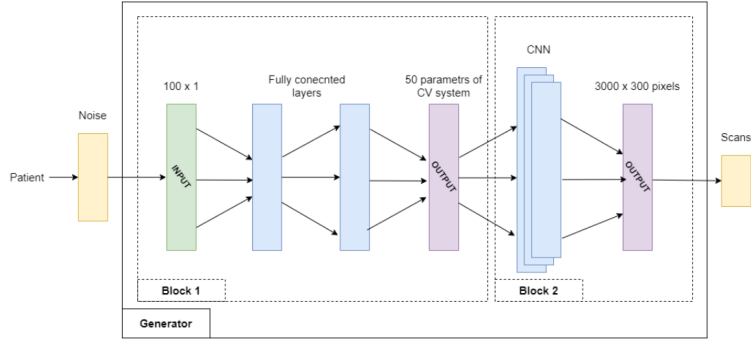


Рисунок 6 — Генератор

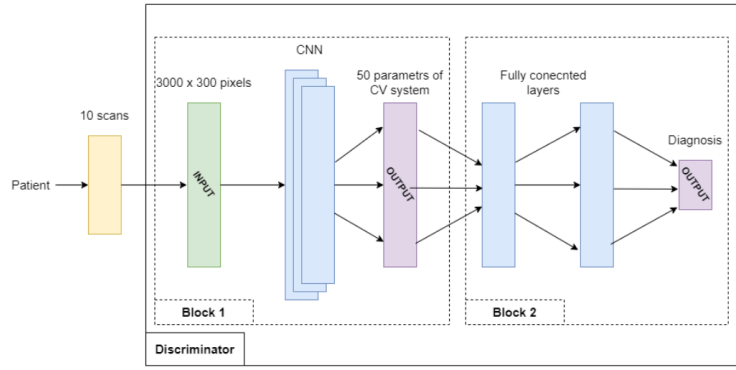


Рисунок 7 — Дискриминатор

системы и информацию о диагнозе. В качестве оптимизатора был выбран обычный Adam.

Также в модификации используется дополнительная функция потерь, ее задача в приведении работы модели в связи с законами гемодинамики.

$$\begin{aligned}
 \text{Loss}_{\text{residuals}} = & \frac{1}{N} \sum_{i=0}^N \left(S_0^i v_0^i - \sum_{j=1}^{n_i} (S_j^i v_j^i) \right)^2 + \\
 & + \frac{1}{N} \sum_{i=0}^N \left(\sum_{j=1}^{n_i} \left(p_0^i + \frac{1}{2} \rho(v_0^i)^2 - p_j^i - \frac{1}{2} \rho(v_j^i)^2 \right) \right)^2 + \\
 & + \frac{1}{N_c} \sum_{i=N}^{(N+N)_c} \left(\sum_{j=1}^{n_i} \left(p_0^i + \frac{1}{2} \rho(v_0^i)^2 - p_j^i - \frac{1}{2} \rho(v_j^i)^2 - \Delta p_{\text{сердце}} \right) \right)^2 + \\
 & + \frac{1}{N_k} \sum_{i=(N+N)_c}^{(N+N)_c+N_k} \left(\sum_{j=1}^{n_i} \left(p_0^i + \frac{1}{2} \rho(v_0^i)^2 - p_j^i - \frac{1}{2} \rho(v_j^i)^2 - \Delta p_{\text{капилляры}} \right) \right)^2
 \end{aligned}$$

Где N представляет собой число вершин, в невязках которых присутствует $\Delta p_{\text{сердце}}$, N - число вершин, в невязках которых присутствует

$\Delta p_{\text{капилляры}}$, N - число остальных вершин в графе, n_i - число исходящих из i -ой вершины ребер, $(S^i)_j$, v_j^i , p_j^i - параметры j -го ребра, исходящего из i -ой вершины.

Как альтернативный метод были рассмотрены дополнительные модификации функции потерь, но они не показали должного улучшения предсказаний, а даже уменьшили его.

3.3 Результаты

В первую очередь были проведены эксперименты с стандартной моделью GAN и моделью с использованием малого кровеносного графа, на практике большую пользу дает именно малый, так как по факту большой граф просто увеличивает число нейронных связей в блоках с параметрами PINN, что вообще не означает что модель работает лучше.




Рисунок 8 — Accuracy, Precision, Recall для модели с PINN и без

Анализируя графики, становится ясно, что модель без использования парадигмы PINN (справа) ошибочно классифицирует всех пациентов как здоровых. Однако модель с применением PINN демонстрирует значительно лучшую и более стабильную работу. Это подтверждает преимущества внедрения физической информации о кровеносной системе и ограничений на параметры кровотока, что позволяет более точно и надежно определять состояние пациента.

Теперь рассмотрим графики функции потерь этих моделей. Хотя модель без PINN сходится быстрее, но график функции потерь модели с PINN после 200 эпохи становится плавнее и начинает сходиться.

Для экспериментирования с моделями PINN, также была попытка использовать сигмоидальную функцию для выходы дискриминатора, чтобы




Рисунок 9 — Функции потерь для модели с PINN и без

вывод был в заранее заданном интервале. Но данный метод сильно замедляет обучение нашей сети. Функции потерь очень плохо сходятся, но это не слишком оказывает большого влияния вообще на работаспособность модели.

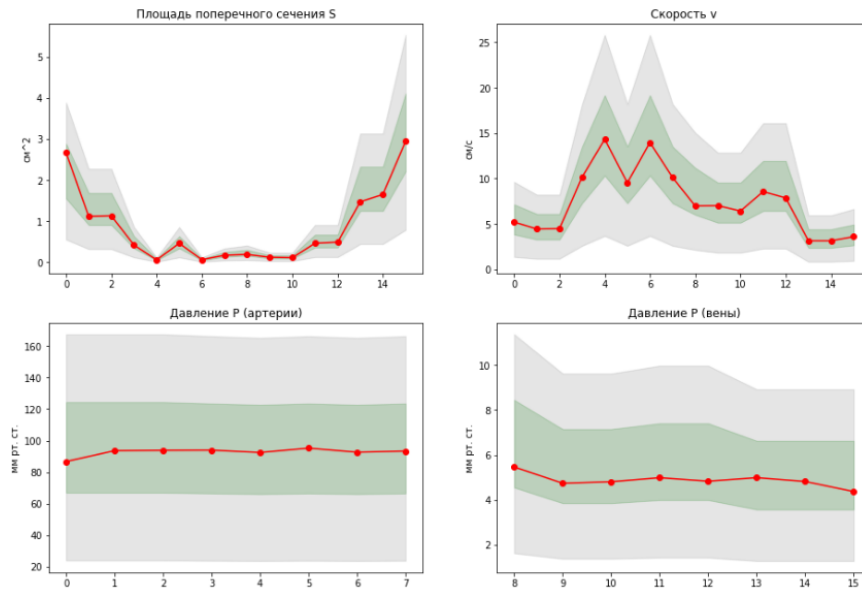


Рисунок 10 — Соответствие законам гемодинамики

3.4 Бифуркационный анализ

Чтобы избежать blackbox, нашей сети было предложено использование бифуркационного анализа чтобы определять какие параметры отвечают за прохождение устойчивых состояний кровеносной системы. За основу также взять малый граф кровеносной системы. Для построения карты с точками бифуркаций использовался метод пристрелки для решения краевых задач системы дифференциальных уравнений.

ЗАКЛЮЧЕНИЕ

В рамках данного исследования были достигнуты следующие цели:

1. Был выполнен обзор литературы по задачам флебологии.
2. Предложены методы аугментации медицинских изображений.
3. Изучены законы гемодинамики и определены физические уравнения, описывающие движение крови в сосудах, для интеграции их в модель нейронной сети.
4. Рассмотрено несколько модификаций стандартной модели GAN.
5. Проведен вычислительный эксперимент с помощью суперкомпьютера ВШЭ.
6. Предложены рекомендации по улучшению перспективных моделей.

В результате исследования с использованием вычислительного эксперимента было показано, что применение парадигмы PINN улучшает качество генерации МРТ-снимков по сравнению со стандартной моделью GAN. Наилучший результат был достигнут с использованием модели, в которую была внедрена физическая информация об упрощенном графе кровеносной системы. Предобученная модель показала высокое качество работы как генератора, так и дискриминатора, что подтверждается стандартными метриками Precision, Accuracy, Recall, а также значениями комбинированной функции потерь. Более того, наблюдается заметное улучшение правдоподобности генерируемых изображений по сравнению со стандартной моделью GAN. Таким образом, результаты исследования можно считать успешными.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *Statistics A.B. of. Causes of Death, Australia.* — 2021. — URL: <https://www.abs.gov.au/statistics/health/causes-death/causes-death-australia/latest-release>. ABS.
2. *American Heart Association. Heart Disease and Stroke Statistics - 2022 Update.* — 2022. — <https://professional.heart.org/en/science-news/heart-disease-and-stroke-statistics-2022-update>.
3. *Hatami N., Goldbaum M.* Automatic identification of retinal arteries and veins in fundus images using local binary patterns // arXiv preprint arXiv:1605.00763. — 2016.
4. *Basu S. [et al.].* Segmentation of Blood Vessels, Optic Disc Localization, Detection of Exudates, and Diabetic Retinopathy Diagnosis from Digital Fundus Images // Proceedings of Research and Applications in Artificial Intelligence. — 2021. — P. 173–184.
5. *Abdou M.A.H.M., Truong T.T., Jul E., Ferreira P.* Deep Learning and Computer Vision Techniques for Microcirculation Analysis: A Review // arXiv preprint arXiv:2205.05493. — 2022.
6. *Abdou M.A., Team A., [et al.].* Exploring novel high power density concepts for attractive fusion systems // Fusion Engineering and Design. — 1999. — Vol. 45, no. 2. — P. 145–167.
7. *Abdou M.A.* Literature review: efficient deep neural networks techniques for medical image analysis // Neural Computing and Applications. — 2022. — Vol. 34, no. 8. — P. 5791–5812.
8. *Guo Z., Luan Y., Feng J., [et al.].* Cerebrovascular Segmentation via Vessel Oriented Filtering Network // arXiv preprint arXiv:2210.08868. — 2022.
9. *Yousefirizi F. [et al.].* AI-Based Detection, Classification and Prediction/Prognosis in Medical Imaging // PET Clinics. — 2022. — Vol. 17, no. 1. — P. 183–212.

10. *Viqar M., Madjarova V., Yadav A.K., Pashkuleva D., Machikhin A.S.* Deep Learning based Segmentation of Optical Coherence Tomographic Images of Human Saphenous Varicose Vein. — 2023. — arXiv: [2303.01054 \[eess.IV\]](#).
11. *Morales X., Mill J., Simeon G., [et al.].* Geometric Deep Learning for the Assessment of Thrombosis Risk in the Left Atrial Appendage. — 2022. — arXiv: [2210.10563 \[cs.LG\]](#).
12. *Гусев А., Гаврилов Д., Корсаков И.* [и др.]. Перспективы использования методов машинного обучения для предсказания сердечно-сосудистых заболеваний // Искусственный интеллект в здравоохранении. — 2019. — № 3. — С. 41—45.
13. *Гусев А.* Перспективы нейронных сетей и глубокого машинного обучения в создании решений для здравоохранения // Искусственный интеллект в здравоохранении. — 2017. — № 3. — С. 93—105.